

1. Ejemplos de estimacion puntual

1.1. Ejercicio 1 - Distribucion Normal

Se quiere conocer el peso medio de los paquetes de arroz producido por una fábrica. Para ello se toman 30 cajas de arroz al azar y se las pesa. Se obtiene

0,96	0,97	1,12	1,16	1,03	0,95	0,91	0,87	0,96	1,04
0,77	0,99	0,84	1,08	1,12	0,78	0,95	0,93	1,09	0,92
1,00	0,92	1,02	0,90	0,87	0,85	1,03	1,04	0,92	1,07

Supongamos que el peso de un paquete elegido al azar es una variable aleatoria $X \sim \mathcal{N}(\mu, \sigma^2)$

Al elegir n paquetes tenemos: Sea X_1, X_2, \dots, X_n i.i.d. $X_i \sim \mathcal{N}(\mu, \sigma^2)$ Estimador de los momentos de μ de orden 1:

$$\frac{1}{n} \sum_{i=1}^n X_i = E_{\hat{\mu}}(X) = \hat{\mu}$$

Con estos datos la estimacion que se obtiene es $\hat{\mu}_{obs} = 0,97$

1.2. Ejercicio 2 - Distribucion Exponencial

Una fabrica de lamparas sabe que el tiempo de vida, en dias, de las lamparas que fabrica, sigue una distribucion $Exp(\theta)$. Obtener una formula para estimar θ a partir de una muestra aleatoria $X_1 \dots X_n$

Antes de probar las lamparas no sabemos cuanto durara cada una. Asi la duracion de la primera puede ser considerada una v.a X_1 . la segunda una v.a X_2 , etc.

$$X_1, X_2, \dots, X_n \sim Exp(\theta)$$

Para hallar el estimador de momentos de θ , hay que despejar $\hat{\theta}$ de

$$\frac{1}{n} \sum_{i=1}^n X_i = E_{\hat{\theta}}(X_1)$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\theta} \Rightarrow \theta = \frac{1}{\bar{X}}$$

1.3. Ejercicio 3 - Distribucion uniforme

$$X_1, X_2, \dots, X_n \sim \mathcal{U}(0, \theta)$$

Hay que despejar θ de

$$\frac{1}{n} \sum_{i=1}^n X_i = E_{\hat{\theta}}(X_1)$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\theta}}{2} \Rightarrow \theta = 2 \frac{1}{n} \sum_{i=1}^n X_i$$

1.4. Ejercicio 4 - Estimacion de ambos parametros de la normal

Supongamos que tenemos una muestra aleatoria $X_1, X_2, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$
Se tiene que $E_{\mu, \sigma^2}(X) = \mu$ y $E_{\mu, \sigma^2}(X^2) = \mu^2 + \sigma^2$ Para encontrar el estimador de momentos de μ y σ hay que resolver el sistema

$$\frac{1}{n} \sum_{i=1}^n X_i = E_{\hat{\mu}, \hat{\sigma}^2}(X_1) = \hat{\mu}$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = E_{\hat{\mu}, \hat{\sigma}^2}(X_1^2) = \hat{\mu}^2 + \hat{\sigma}^2$$

$$\begin{cases} \frac{1}{n} \sum_{i=1}^n X_i = \hat{\mu} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \hat{\mu}^2 + \hat{\sigma}^2 \end{cases}$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i\right)^2$$

2. Ejemplos de estimacion puntual - Verosimilitud

2.1. Ejercicio 1 - $\mathcal{E}(\lambda) : f(x, \lambda) = \lambda e^{-x\lambda} \mathcal{I}_{(0, \infty)}(x)$

X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{E}(\lambda), \lambda > 0$

$$L(\lambda; x) = \prod_{i=1}^n f(x_i, \lambda) = \prod_{i=1}^n \lambda e^{-x_i \lambda} \mathcal{I}_{(0, \infty)}(x_i)$$

Si $x_i \geq 0 \forall i$

$$L(\lambda; x) = \lambda e^{-x_i \sum_{i=1}^n x_i}$$

Si consideramos $\log L$ resulta

$$l(\lambda; x) = n \log(\lambda) - \lambda \sum_{i=1}^n x_i$$

Derivando e igualando a 0 queda

$$\frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \Rightarrow \text{punto critico es } \frac{1}{\bar{x}_n}, \text{ ver que maximiza}$$

$$\Rightarrow \hat{\lambda} = \frac{1}{\bar{x}_n}$$

2.2. Ejercicio 2 - X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{N}(\mu, 9), f(x, \mu, 9) = \frac{1}{\sqrt{2\pi} \cdot 3} e^{-\frac{1}{2} \frac{(x-\mu)^2}{9}}$

$$L(\mu, 9; x) = \prod_{i=1}^n f(x_i, \mu, 9) = \prod_{i=1}^n \frac{1}{\sqrt{(2\pi)}} \frac{1}{3} e^{-\frac{1}{2} \frac{(x_i - \mu)^2}{9}}$$

$$L(\mu, 9; x) = \left(\frac{1}{\sqrt{(2\pi)}}\right)^n \left(\frac{1}{3}\right)^n e^{-\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu)^2}{9}}$$

Tomemos logaritmo

$$l(\mu, 9; x) = n \log \left(\frac{1}{\sqrt{(2\pi)}} \right) - \frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu)^2}{9}$$

Maximizar a $l(\mu, 9; x)$ como funcion de μ equivale a minimizar

$$h(\mu) = \sum_{i=1}^n (x_i - \mu)^2$$

Un par de clases aatras vimos que $h(\mu)$ se minimiza en \bar{x}_n

$$EMV \text{ de } \mu : \hat{\mu} = \bar{X}_n$$

$$L(\mu, 9; x) = \prod_{i=1}^n f(x_i, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{(2\pi\sigma^2)}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$L(\mu, \sigma^2; x) = \prod_{i=1}^n f(x_i, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

Tomando logaritmo y resolviendo las ecuaciones

$$\frac{\partial l(\mu, \sigma^2; x)}{\partial \mu} = 0 \text{ y } \frac{\partial l(\mu, \sigma^2; x)}{\partial \sigma^2} = 0$$

se obtiene que los EMV de μ y σ^2 son

$$\hat{\mu} = \bar{X}_n \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n ((X_i - \bar{X}_n))^2}{n}$$

Los estimadores de μ y σ coinciden con los estimadores de momentos

2.3. Ejercicio 2 - $\mathcal{U}(0, \theta) : f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{(0, \theta)}(x)$

X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{U}(0, \theta)$

$$f(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathcal{I}_{(0, \theta)}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathcal{I}_{(0, \theta)}(x_i)$$

La indicadora vale 1 cuando todas las indicadoras valgan 1, de lo contrario, es 0. Por ende, la conjunta puede tomar 2 valores:

$$\begin{cases} \frac{1}{\theta^n} & \text{si } 0 < x_i < \theta \quad \forall i \\ 0 & \text{en otro caso} \end{cases}$$

$$\begin{cases} \frac{1}{\theta^n} & \text{si } \theta > \max(x_i) \\ 0 & \text{en otro caso} \end{cases}$$

3. Propiedades de estimacion

3.1. Ejercicio 1 - Distribucion Uniforme

- $X_i \sim \mathcal{U}(0, \theta)$
- $\hat{\theta} = 2\bar{X}_n$ (Estimador de momentos)
- $\hat{\theta} = \max X_1, \dots, X_n$ (Estimador de maxima Verosimilitud)
- Calcule la esperanza y varianza de cada estimador

Esperanza del estimador de momentos Sea X_1, X_2, \dots, X_n una m.a de una distribucion $\mathcal{U}(0, \theta)$. El estimador de momentos de θ es $\hat{\theta} = 2\bar{X}$

$$E_{\theta}(\hat{\theta}) = 2E_{\theta}\bar{X} = 2\frac{\theta}{2} = \theta \quad \forall \theta$$

Recordar

Sea X_1, X_2, \dots, X_n una m.a de una distribucion $\mathcal{U}(0, \theta)$

- El EMV de $\theta = \max_{1 \leq i \leq n} (X_i)$
- La fda es $\hat{\theta}$ es

$$F_{\hat{\theta}}(u) = (F_{X_i}(u))^n = \begin{cases} 0 & \text{si } u \leq 0 \\ (\frac{u}{\theta})^n & \text{si } 0 < u < \theta \\ 1 & \text{si } u \geq \theta \end{cases}$$

- La densidad de $\hat{\theta}$ es

$$f_{\hat{\theta}}(u) = n \frac{u^{n-1}}{\theta} \frac{1}{\theta} I_{(0, \theta)}(u)$$

$$E_{\theta}(\hat{\theta}) = \int_0^{\theta} u n \left(\frac{u}{\theta}\right)^{n-1} \frac{1}{\theta} du = \frac{n}{\theta^n} \int_0^{\theta} u^n du = \frac{n}{\theta^n} \frac{u^{n+1}}{n+1} \Big|_0^{\theta} = \frac{n}{n+1} \theta$$

Varianza del estimador de momentos

Sea X_1, X_2, \dots, X_n una m.a de una distribucion $\mathcal{U}(0, \theta)$ y $\hat{\theta} = 2\bar{X}$ el estimador de momentos de θ

$$V_{\theta}(\hat{\theta}) = 4V_{\theta}(\bar{X}) = 4 \frac{\theta^2/12}{n}$$

Varianza del estimador de maxima Verosimilitud Recordar la densidad del EMV

$$\begin{aligned} f_{\theta}(u) &= n \frac{u^{n-1}}{\theta} \frac{1}{\theta} I_{(0, \theta)}(u) \\ E_{\theta}(\hat{\theta}^2) &= \int_0^{\theta} u^2 n \frac{u^{n-1}}{\theta} \frac{1}{\theta} du = \frac{n}{\theta^n} \int_0^{\theta} u^{n+1} du \\ &= \frac{n}{\theta^n} \frac{u^{n+2}}{n+2} \Big|_0^{\theta} = \frac{n}{n+2} \theta^2 \end{aligned}$$

Entonces,

$$\begin{aligned} V_{\theta}(\hat{\theta}) &= \frac{n}{n+2} \theta^2 - \left(\frac{n}{n+1}\right)^2 \theta^2 = \left(\frac{n}{n+2} - \frac{n^2}{(n+1)^2}\right) \theta^2 \\ &= \frac{n}{(n+2)(n+1)^2} \theta^2 \end{aligned}$$

3.2. Ejercicio 2 - Sesgo de los EMV de μ y σ^2 en el caso normal

Sea X_1, X_2, \dots, X_n una m.a de una distribución $\mathcal{N}(\mu, \sigma^2)$. Los EMV de μ y σ^2 son

$$\hat{\mu} = \bar{X} \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$$

- El estimador de μ es insesgado pues $E_{\mu, \sigma^2}(\hat{\mu}) = \mu \forall \mu$,
- El estimador de σ^2 es sesgado pero es asintóticamente insesgado pues:

$$\begin{aligned} E_{\mu, \sigma^2}(\hat{\sigma}^2) &= E_{\mu, \sigma^2}\left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}\right) \\ &= \frac{1}{n} E_{\mu, \sigma^2}\left(\sum_{i=1}^n (X_i^2 - 2X_i \bar{X} + \bar{X}^2)\right) \\ &= \frac{1}{n} E_{\mu, \sigma^2}\left(\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right) \\ &= \frac{1}{n} E_{\mu, \sigma^2}\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) \\ &= \frac{1}{n} E_{\mu, \sigma^2}\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right) \\ &= \frac{1}{n} E_{\mu, \sigma^2}\left(\sum_{i=1}^n X_i^2\right) - E_{\mu, \sigma^2}(\bar{X}^2) \\ &= \frac{n}{n} E_{\mu, \sigma^2}(X_1^2) - E_{\mu, \sigma^2}(\bar{X}^2) \\ &= [V_{\mu, \sigma^2}(X_1) + (E_{\mu, \sigma^2}(X_1))^2] - [V_{\mu, \sigma^2}(\bar{X}) + (E_{\mu, \sigma^2}(\bar{X}))^2] \\ &= \sigma^2 + \mu^2 - \frac{\sigma^2}{n} - \mu^2 \\ &= \frac{n-1}{n} \sigma^2 \end{aligned}$$

3.3. Ejemplo - Consistencia de la media muestral

Sea X_1, X_2, \dots, X_n una m.a de una distribución con $E(X_i) = \mu$ y $V(X_i) = \sigma^2 < \infty$. Sea $\hat{\mu} = \bar{X}$

- $E(\bar{X}) = \mu$
- $V(\bar{X}) = \frac{\sigma^2}{n}$

Entonces $\hat{\mu}$ es un estimador consistente de μ

3.4. Ejemplo - Consistencia de los estimadores de θ en la $\mathcal{U}[0, \theta]$

Sea X_1, X_2, \dots, X_n una m.a de una distribución $\mathcal{U}(0, \theta)$. Vimos que el EMV de θ , $\hat{\theta} = \max_{1 \leq i \leq n} (X_i)$ y

- $E_{\theta}(\hat{\theta}) = \frac{n}{n+1} \theta \Rightarrow \hat{\theta}$ es asintóticamente insesgado
- $V_{\theta}(\hat{\theta}) = \frac{n}{(n+2)(n+1)^2} \theta^2 \rightarrow_{n \rightarrow \infty} 0$

Entonces el $\hat{\theta}$ es consistente

3.5. Ejemplo - Consistencia de la varianza muestral

Sea X_1, X_2, \dots, X_n una m.a de una con $E(X_i) = \mu$ y $V(X_i) = \sigma^2 < \infty$ entonces la varianza muestral S^2 es un estimador consistente de la varianza poblacional

$$\begin{aligned} S^2 &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1} = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) \\ &= \frac{n}{n-1} \left(\frac{\sum_{i=1}^n X_i^2}{n} - \bar{X}^2 \right) \end{aligned}$$

Por la Ley de los Grandes Numeros $\bar{X} \xrightarrow{p} \mu$, entonces por la propiedad 4,

$$\bar{X}^2 \xrightarrow{p} \mu^2$$

Por otra parte, aplicando nuevamente la Ley de los grandes Numeros

$$\frac{\sum_{i=1}^n X_i^2}{n} \xrightarrow{p} E_{\mu, \sigma^2}(X^2) = V_{\mu, \sigma^2}(X) + [E_{\mu, \sigma^2}(X)]^2 = \sigma^2 + \mu^2$$

Como ademas $\frac{n}{n-1} \rightarrow 1$, se obtiene

$$S_x^2 = \frac{n}{n-1} \left(\frac{\sum_{i=1}^n X_i^2}{n} - \bar{X}^2 \right) \xrightarrow{p} \sigma^2 + \mu^2 - \mu^2 = \sigma^2$$

y por lo tanto la varianza muestral es un estimador consistente de σ^2

4. Intervalos de confianza

4.1. Ejemplo - Intervalo de confianza para el parametro de la exponencial

- Si Z_1, \dots, Z_n i.i.d., $Z_i \sim \mathcal{N}(0, 1)$, llamamos chi cuadrado con n grados de libertad a la distribucion de

$$Z_1^2 + Z_2^2 + \dots + Z_n^2$$

- la suma de n v.a. χ_1^2 tiene distribucion χ_n^2
- Ejercicio 23 de la practica 3.** Sea Z una v.a. con una distribucion normal standar. Pruebe que $Z^2 \sim \Gamma(1/2, 1/2)$ (Esta variable aleatoria recibe el nombre de χ^2 con un grado de libertad)
- Una suma de n v.a. χ_1^2 es $\Gamma(n/2, 1/2)$. Por lo tanto,

$$\Gamma(n/2, 1/2) = \chi_n^2$$

Sea X_1, X_2, \dots, X_n una m.a. de una distribucion $E(\lambda)$ Recordar:

- La distribucion de la suma de exponenciales es Gamma, es decir

$$\sum_{i=1}^n X_i \sim \Gamma(n, \lambda)$$

- Una constante por una Gamma es Gamma:

■

$$V \sim \Gamma(\alpha, \lambda) \text{ y } a > 0 \Rightarrow aV \sim \Gamma(\alpha, \frac{\lambda}{a})$$

Por lo tanto

$$\begin{aligned} \sum_{i=1}^n X_i &\sim \Gamma(n, \lambda) \\ \lambda \sum_{i=1}^n X_i &\sim \Gamma(n, 1) \\ 2\lambda \sum_{i=1}^n X_i &\sim \Gamma(n, \frac{1}{2}) = \Gamma(\frac{2n}{2}, \frac{1}{2}) = \chi_{2n}^2 \end{aligned}$$

Pivot para la exponencial:

$$H(X_1, X_2, \dots, X_n, \lambda) = 2\lambda \sum_{i=1}^n X_i$$

$$\begin{aligned} P\left(\chi_{2n, 1-\alpha/2}^2 \leq 2\lambda \sum_{i=1}^n X_i \leq \chi_{2n, \alpha/2}^2\right) &= 1 - \alpha \\ P\left(\frac{\chi_{2n, 1-\alpha/2}^2}{2 \sum_{i=1}^n X_i} \leq \lambda \leq \frac{\chi_{2n, \alpha/2}^2}{2 \sum_{i=1}^n X_i}\right) &= 1 - \alpha \end{aligned}$$

Entonces el intervalo de confianza para λ

$$\left[\frac{\chi_{2n, 1-\alpha/2}^2}{2 \sum_{i=1}^n X_i}, \frac{\chi_{2n, \alpha/2}^2}{2 \sum_{i=1}^n X_i} \right]$$

4.2. Ejemplo - Intervalo de confianza para θ en la $\mathcal{U}[0, \theta]$

Sea X_1, X_2, \dots, X_n una m.a. de una distribucion $U(0, \theta)$

- el EMV de θ es $\hat{\theta} = \max(X_1, \dots, X_n)$

■ la distribución de $\max(X_1, \dots, X_n)$ es $(F_{x_1}(u))^n$

■ La fda de $\hat{\theta}$ esperanza

$$F_{\hat{\theta}}(u) = (F_{x_1}(u))^n = \begin{cases} 0 & \text{si } u \leq 0 \\ \left(\frac{u}{\theta}\right)^n & \text{si } 0 < u < \theta \\ 1 & \text{si } u \geq \theta \end{cases}$$

■ la densidad de $\hat{\theta}$ es

$$f_{\hat{\theta}}(u) = n \left(\frac{u}{\theta}\right)^{n-1} \frac{1}{\theta} I_{(0,\theta)}(u)$$

Veamos que la distribución de $\hat{\theta}/\theta$ no depende de θ

Queremos demostrar que la distribución de $\hat{\theta}/\theta$ no depende de θ

$$F_{\hat{\theta}/\theta}(u) = P\left(\frac{\hat{\theta}}{\theta} \leq u\right) = P(\hat{\theta} \leq \theta u) = F_{\hat{\theta}}(\theta u) = (F_{x_1}(\theta u))^n$$

Como $X_i \sim U(0, \theta)$

$$\begin{aligned} F_{\hat{\theta}}(u) &= (F_{x_1}(u))^n = \begin{cases} 0 & \text{si } u \leq 0 \\ \left(\frac{u}{\theta}\right)^n & \text{si } 0 < u < \theta \\ 1 & \text{si } u \geq \theta \end{cases} \\ &= \begin{cases} 0 & \text{si } u \leq 0 \\ \left(\frac{u}{\theta}\right)^n & \text{si } 0 < u < \theta \\ 1 & \text{si } u \geq \theta \end{cases} \end{aligned}$$

Por lo tanto, la distribución de $\hat{\theta}/\theta$ no depende de θ . Derivando, se obtiene la densidad de $\hat{\theta}/\theta$

$$f_{\hat{\theta}/\theta}(u) = nu^{n-1} I_{(0,1)}(u)$$

Pivot:

$$H(X_1, X_2, \dots, X_n, \theta) = \frac{\max(X_1, \dots, X_n)}{\theta}$$

Buscamos a y b tales que

$$P\left(a \leq \frac{\max(X_1, \dots, X_n)}{\theta} \leq b\right) = 1 - \alpha$$

y, obtenemos el siguiente intervalo

$$\left[\frac{\max(X_1, \dots, X_n)}{b}, \frac{\max(X_1, \dots, X_n)}{a}\right]$$

¿Y como elegimos a y b ? Debemos hallar a y b , $0 < a < b < 1$, tales que

$$\int_a^b nw^{n-1}dw = w^n|_a^b = b^n - a^n = 1 - \alpha \quad (1)$$

Conviene elegir la solución que produce el intervalo de menor longitud esperada, es decir, buscar a y b que minimicen $E(L)$ siendo

$$L = \max(X_1, \dots, X_n) \left(\frac{1}{a} - \frac{1}{b}\right)$$

sujeto a la condición $b^n - a^n = 1 - \alpha$ Como ya hemos demostrado que $E(\max(X_1, \dots, X_n)) = \frac{n}{n+1}\theta$, debemos minimizar

$$\frac{n}{n+1}\theta \left(\frac{1}{a} - \frac{1}{b}\right)$$

sujeto a la condición $b^n - a^n = 1 - \alpha$ El intervalo de mínima longitud esperada es

$$\left(\frac{\max X_1, \dots, X_n}{1}, \frac{\max(X_1, \dots, X_n)}{\sqrt[n]{\alpha}}\right)$$

4.3. Intervalo de confianza asintotico para el parametro p de la distribucion binomial

4.3.1. Aproximacion normal a la binomial

Sea $X \sim Bi(n, p)$, entonces X es el nuumero de exitos en n repeticiones de un experimento binomial con probabilidad de exito igual a p Sea, para $i = 1, \dots, n$,

$$X_i = \begin{cases} 1 & \text{si se obtuvo exito en la } i\text{-esima repeticiones} \\ 0 & \text{si se obtuvo fracaso en la } i\text{-esima repeticion} \end{cases}$$

Estas v.a. son indepentientes, $X_i \sim Bi(1, p) \forall i$ y

$$X = \sum_{i=1}^n X_i$$

A demas $E(X_i) = p$ y $V(X_i) = p(1 - p)$. Entonces, por TCL

$$\frac{X - np}{\sqrt{np(1 - p)}} \stackrel{a}{\sim} N(0, 1) \text{ y } \frac{\bar{X} - p}{\sqrt{p(1 - p)/n}} \stackrel{a}{\sim} N(0, 1)$$

Sea X_1, X_2, \dots, X_n una m.a. de una distribucion $B(1, p)$

$$\frac{\bar{X} - p}{\sqrt{p(1 - p)/n}} \stackrel{a}{\sim} N(0, 1)$$

Implica que

$$P \left(-z_{\alpha/2} \leq \frac{\bar{X} - p}{\sqrt{\frac{p(1-p)}{n}}} \leq z_{\alpha/2} \right) \xrightarrow{n \rightarrow \infty} 1 - \alpha$$

¿Como despejamos p ? Mejor dicho, ¿despejamos p ? Recordar que en este contexto \bar{X} tambien se nota \hat{p}

Como, por la Ley de los Grandes Numeros

$$\hat{p} = \bar{X} = \frac{\sum_{i=1}^n X_i}{n} \xrightarrow{p} p$$

podemos aplicar el teorema de Slutsky y reemplazar en el denominador el pivote p por su estimador. Entonces se tiene que

$$\frac{\bar{X} - p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \xrightarrow{d} N(0, 1)$$

y por lo tanto

$$P \left(-z_{\alpha/2} \leq \frac{\bar{X} - p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \leq z_{\alpha/2} \right) \cong 1 - \alpha$$

Por lo tanto, un intervalo para p de nivel asintotico $1 - \alpha$ esperanza

$$\left[\bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}(1 - \bar{X})}{n}}, \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}(1 - \bar{X})}{n}} \right]$$

o, lo que es lo mismo

$$\left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right]$$